

딥러닝 기반 역방향 해석을 이용한 비파괴
압입 실험으로부터의
재료 기계적 특성 및 잔류응력 추정
(Prediction of Mechanical Properties and Residual Stress
from Spherical Indentation Experiments via
Deep-Learning-Based Inverse Analysis)

지도교수 : 한홍남

이 보고서를 공학학사 학위 논문
대체 보고서로 제출함.

2026년 6월 9일

서울대학교 공과대학
재 료 공 학 부
임 세 용

2026년 8월

국문초록

본 연구는 비파괴 검사법인 계장화 구형 압입시험(instrumented spherical indentation test)으로부터 재료의 소성 경화 거동과 이축(二軸) 잔류응력을 동시에 추정하는, 딥러닝 기반 역방향 해석(inverse analysis) 프레임워크를 제안한다. 압입 기반 역문제는 서로 다른 물성 조합이 유사한 압입 응답을 재현하는 비유일성(non-uniqueness)과, 미소한 측정 노이즈에도 해가 크게 변동하는 악조건성(ill-conditioning)을 본질적으로 내포한다. 특히 잔류응력은 하중-깊이(load-depth) 곡선에는 거의 영향을 주지 않는 반면 압입 후 잔류 표면 형상(residual imprint)에는 뚜렷한 흔적을 남기므로, 본 연구는 잔류 z-프로파일(residual z-profile)을 핵심 입력으로 활용한다.

Swift 경화 법칙과 von Mises 항복 기준에 기반하여 정의된 1,999개의 파라미터 조합에 대해 유한요소해석(FEA)을 수행하고, 하중-깊이 곡선과 잔류 z-프로파일로 구성된 합성 데이터베이스를 구축하였다. 이를 입력으로 하여 경화 파라미터(K , ϵ_0 , n)와 이축 잔류응력(R_{sx} , R_{sy})을 출력하는 인공신경망(ANN)을 학습하였다. 시뮬레이션-실험 간극(sim-to-real gap)을 완화하기 위해 시계열 데이터에 널리 쓰이는 세 가지 데이터 증강 기법(Gaussian jittering, magnitude warping, masking)을 적용하였으며, 잔류 프로파일의 물리 기반 스칼라 특징과 잠재특징(latent feature) 추출 모델(CNN, VAE, LSTM)의 효과를 SMAPE 지표로 비교하였다.

그 결과 경화 파라미터에서는 CNN이, 잔류응력에서는 VAE가 상대적으로 우수하였다. 다만 실제 실험에서 직접 검증 가능한 경화곡선 복원과 전반적 학습 안정성을 함께 고려하여, 본 연구의 최종 구성은 CNN과 masking의 결합으로 설정하였다. 최종 모델은 시험(시뮬레이션) 데이터에서 대부분의 파라미터에 대해 높은 결정계수를 보였으며, 실제 구리(Cu) 시편의 압입 응답으로부터 복원한 응력-변형률 곡선도 일축 인장시험 결과와 합리적으로 일치하였다. 반면 ϵ_0 와 잔류응력 추정은 접촉부 z-프로파일의 시뮬레이션-실험 간극에 민감하였으며, 이를 입력 정보의 한계, Swift 식의 항복 부근 불확실성, 접촉부 탄성회복 차이 측면에서 분석하였다. 본 연구는 단일 비파괴 압입 응답으로부터 경화 물성과 잔류응력을 동시에 추정하는 가능성을 보였다는 점에서 의의가 있으며, 향후 다중충실도 신경망(MFNN) 및 물리정보 신경망(PINN)으로의 확장 가능성을 제시한다

주요어 : 계장화 압입시험, 잔류응력, 역방향 해석, 인공신경망, 데이터 증강

제 1 장 서론

제 1 절 연구 배경

재료의 기계적 특성, 특히 소성 유동(plastic flow) 거동은 성형성, 구조 건전성, 사용 중 변형 응답을 좌우하는 핵심 물성이다. 전통적으로 이러한 특성은 일축 인장시험과 같은 파괴적 시험으로 측정되어 왔으나, 시편 가공의 제약, 시험 비용과 시간, 그리고 소형 부품이나 실제 사용 중 부재에 대한 적용의 한계로 인해 비파괴적 대안의 필요성이 꾸준히 제기되어 왔다. 이러한 배경에서 하중과 침투 깊이의 연속 변화를 정밀하게 기록하는 계장화 압입시험(instrumented indentation test, IIT)은 국부 영역의 기계적 특성을 효율적으로 평가할 수 있는 유력한 방법으로 자리잡았다. 특히 구형 압입은 접촉 반경이 점진적으로 증가하면서 탄성-소성 천이가 비교적 안정적으로 진행되어, 하중-깊이 곡선과 압입 후 잔류 표면 형상에 재료 정보가 복합적으로 반영된다는 장점을 가진다.^{[1],[2]} 계장화 구형 압입시험은 표준 시편을 만들기 어려운 경우 등 인장시험을 진행하기 힘든 경우 유동 물성과 경화 거동을 비파괴적으로 추정하는 방법으로도 연구되어 왔다.^[9]

압입 기반 물성평가는 1976년 Francis가 평균 접촉압력에 따라 압입 거동을 탄성, 탄성-소성, 완전소성 영역으로 분류한 이래 활발히 연구되어 왔다.^{[2],[14]} 그러나 소성변형을 포함하는 단계에서는 특정 물성 범위에 대해 보정된 반경험식만이 존재할 뿐, 임의의 재료에 보편적으로 적용 가능한 결정론적 알고리즘은 아직 확립되지 않았다. 또한 재료에 사전 잔류응력이 존재할 경우, 이는 압입 곡선과 잔류 자국 형상을 함께 변화시키며, 항복 강도와 비에 따라 표면이 솟아오르는 pile-up 또는 가라앉는 sink-in 거동을 유발한다.^[11]

제 2 절 연구 문제와 필요성

압입 응답과 재료 물성 사이의 관계는 본질적으로 강한 비선형성을 가지며, 그 역(逆)은 두 가지 어려움을 동시에 내포한다. 첫째, 서로 다른 물성 조합이 유사하거나 동일한 압입 응답을 재현할 수 있어 해가 하나로 정해지지 않는 비유일(non-unique) 문제가 발생한다. 둘째, 응답에 포함된 작은 노이즈에도 추정 결과가 크게 흔들리는 악조건(ill-conditioned) 문제가 존재한다. 이 때문에 해석식이나 반복 최적화에 기반한 전통적 역해석은 계산 부담이 크고 초기값·알고리즘 강건성에 민감하며, 실험 노이즈가 있을 때 안정적인 예측이 어렵다.^[4]

이러한 한계에 대한 대안으로 인공신경망(artificial neural network, ANN)을 비롯한 데이터 기반 방법론이 부상하였다.^{[4]-[6]} ANN은 명시적 방정식 없이 입력-출력 사이의 복잡한 비선형 관계를 학습하며, 충분한 학습 데이터가 주어지면 반복 역계산 없이 즉각적인

추정을 제공한다. 특히 합성곱 신경망(CNN)이나 오토인코더(AE) 계열의 표현학습(representation learning) 모델은 압입 응답을 저차원 잠재공간에 투영함으로써 실험 노이즈를 효과적으로 제어할 수 있다.^[7] 그러나 잔류응력을 함께 추정하려는 문제에서는, 잔류응력이 하중-깊이 곡선에 거의 흔적을 남기지 않는다는 물리적 사실 때문에, 입력으로 무엇을 사용할 것인가가 모델 선택 못지않게 중요해진다.^[14]

제 3 절 연구 목적

본 연구의 목적은 구형 압입 실험으로부터 얻는 하중-깊이 곡선과 압입 후 잔류 z -프로파일을 이용하여, 재료의 경화 거동과 이축 잔류응력을 동시에 추정하는 딥러닝 기반 역해석 프레임워크를 구축하는 데 있다. 이를 위해 Swift 경화 법칙과 von Mises 항복 기준에 기반한 유한요소해석으로 합성 데이터베이스를 구축하고, 여기서 얻은 하중-깊이 곡선과 잔류 z -프로파일을 입력으로 하여 신경망을 학습한다. 이후 실제 구리 시편의 압입 응답을 모델에 입력하여 경화 파라미터와 잔류응력을 추론하고, 그중 경화 파라미터로 복원한 응력-변형률 곡선을 일축 인장시험 기준값과 비교함으로써 실험 적용 가능성을 평가한다.

본 연구는 특히 다음 세 가지 질문에 초점을 둔다. 첫째, 하중-깊이 곡선에 거의 나타나지 않는 잔류응력 정보를 잔류 z -프로파일에서 얼마나 안정적으로 학습할 수 있는가. 둘째, 원시(raw) 프로파일, 절단(crop) 프로파일, 물리 기반 스칼라 특징을 어떻게 조합할 때 예측 성능과 강건성이 개선되는가. 셋째, 유한요소 기반 합성 데이터로 학습한 모델이 실제 실험 데이터에도 유효한 경화곡선 복원 성능을 유지하는가.

본 연구의 기여는 다음과 같이 요약된다.

1. 단일 비파괴 구형 압입 응답으로부터 등방 경화 파라미터(K, ϵ_0, n)와 이축 잔류응력(R_{sx}, R_{sy})을 동시에 추정하는 딥러닝 역해석 프레임워크를 제안하였다.
2. 잔류 z -프로파일의 입력 표현(원시·절단 프로파일 및 물리 기반 스칼라 특징)과 세 가지 잠재특징 추출기(CNN/VAE/LSTM)를 정량 비교하여 파라미터별로 유리한 구조를 규명하였다.
3. 시계열 데이터 증강으로 sim-to-real 간극을 완화하는 방안을 검토하고, 실제 구리 시편에서 응력-변형률 곡선 복원 가능성을 확인하였다.

제 2 장 이론적 배경

제 1 절 계장화 구형 압입과 접촉역학

계장화 압입시험은 압입자가 시편 표면에 침투하는 동안 하중과 변위를 연속적으로 측

정하여 국부 영역의 기계적 응답을 정량화하는 시험법이다. 비파괴성, 소형 시편 적용성, 표면 인접 영역의 직접 평가 가능성이 주요 장점이다. 구형 압입은 sharp 압입에 비해 접촉 반경의 증가가 연속적이어서 탄성-소성 전이 구간을 부드럽게 관찰할 수 있고, 일축 응력-변형률 곡선과의 상관성 도출에 유리하다.(그림 1.)




그림 1 계장화 구형 압입시험의 개략도(a, Si et al., 2022)와 주요 압입 응답(b, Peng et al., 2018)

탄성 영역에서 구형 압입의 하중 P 와 침투 깊이 h 의 관계는 Hertz 접촉 이론으로 기술되며, 접촉 반경 a 는 근사적으로 $a \approx \sqrt{(Rh)}$ 로 주어진다(R : 압입자 반경).^{[11],[8]} 소성변형이 개입되면 거동은 영역에 따라 달라지는데, Francis(1976)와 Mesarovic and Fleck(1999)은 평균 접촉압력을 기준으로 탄성, 탄성-소성, 유한변형, 완전 소성 영역을 구분하였다. 각 영역에서 평균압력·접촉반경·접촉강성의 관계가 달라지고 기준이 재료의 E/YS (E : 탄성계수, YS : 항복강도) 비에 의존하므로, 학습 데이터를 생성할 때 시편들의 E/YS 범위와 압입 깊이를 적절히 통제하여 유사한 변형 영역대에 위치시키는 것이 중요하다. 압입에서 측정 가능한 대표 응답은 하중-깊이 곡선과 압입 후 잔류 표면 형상이다. 전자는 평균 접촉압, 변형 저항, 경화 거동과 연관되고, 후자는 소성변형이 표면 주변으로 어떻게 분포했는지를 반영한다. Tabor(1951)의 관계에 따르면 구형 압입의 대표 변형률은 $\epsilon_r \approx \beta \cdot a/R$ ($\beta \approx 0.2$)로 근사된다.^[16]

제 2 절 역방향 압입 문제: 비유일성과 악조건성

순방향(forward) 접촉 문제에서는 재료 파라미터와 기하가 주어지면 하중-깊이 곡선과 변형장이 결정된다. 그러나 역문제에서는 이 응답으로부터 원래의 파라미터를 복원해야 하며, 서로 다른 파라미터 조합이 유사한 응답을 만들 수 있다. 특히 하중-깊이 곡선은 방향 평균화된 스칼라 응답이므로, 서로 다른 경화 거동이나 응력 상태가 유사한 곡선 형태로 귀결될 가능성이 있다. 그 결과 역문제는 비유일적(Nonunique)이며, 측정 노이즈·표면 상태·마찰계수·초기 응력 등의 작은 변화에도 해가 크게 달라지는 악조건성(ill-posed)을 가진다.^[7] Jeong et al.(2020)은 기존 해석적·수치적 접근의 정확도가 압입 곡선 적합의 정밀도와 역해석 알고리즘의 강건성에 크게 의존하며, 실제 실험 데이터를 사용할 때 입력 품질이 ANN 성능을 좌우한다고 보고하였다.^[4] 이러한 비유일성·악조건성은 식별 대상이 늘어날수록 심화된다. 본 연구처럼 경화 파라미터에 더하여 이축 잔류응력까지 동시에 추정하려는 경우, 하중-깊이 곡선만으로는 정보가 부족하며 추가적인 변형장 정보가

요구된다. 이는 역문제의 안정화가 단지 더 복잡한 알고리즘의 문제가 아니라, 식별성이 높은 응답을 얼마나 함께 확보하느냐의 문제임을 시사한다(그림 2).




그림 2 비유일·악조건 역방향 압입 문제(Jiao et al., 2024)

제 3 절 잔류응력과 pile-up/sink-in, 그리고 하중-깊이 곡선의 한계점

압입 후 표면의 잔류 형상은 소성 유동의 공간적 분포를 반영한다. 재료가 접촉부 가장 자리에서 솟아오르는 pile-up을 보일지, 표면이 꺼지는 sink-in을 보일지는 항복응력, 경화지수, 탄성-소성 비, 그리고 초기 응력 상태와 밀접하게 관련된다. 선행 연구는 잔류 깊이 비(h_f/h_{max})와 경화 거동에 따라 pile-up과 sink-in을 구분하는 기준을 제시하였으며, 일반적으로 h_f/h_{max} 가 1에 가깝고 경화가 약할수록 pile-up이 우세한 것으로 알려져 있다. pile-up/sink-in을 무시할 경우 접촉면적 추정에 20% 이상의 상당한 오차가 발생할 수 있다.^{[11],[17]}

본 연구가 다루는 잔류응력 추정 문제에서 가장 중요한 물리적 사실은, 사전 잔류응력이 하중-깊이 곡선에는 거의 영향을 주지 않는다는 점이다. Mesarovic and Fleck(1999)은 상사해 및 유한변형 영역에서 잔류응력이 평균 접촉압력, 정규화 접촉면적, 접촉강성에 미치는 영향이 무시할 만하다고 보고하였다.^[14] 본 연구의 첫 하중-깊이 데이터점이 위치하는 유한변형 영역($h/R \approx 0.03$ 부근)에서는 E/YS 효과 역시 P-h 곡선에 미미하게 나타난다. 따라서 잔류응력의 흔적은 하중-깊이 곡선이 아니라 잔류 표면 형상에서 찾아야 하며, 이것이 본 연구가 잔류 z-프로파일을 핵심 입력으로 채택한 직접적 근거이다.

제 4 절 잔류 표면 프로파일의 정보성과 indentation plastometry

Indentation plastometry는 계장화 압입 응답으로부터 재료의 거시적 소성 물성을 역으로 식별하는 방법론을 가리킨다. 초기에는 해석적 상관식이나 대표 변형률 개념이 주로

활용되었으나, 보다 일반적인 구성 거동을 다루기 위해 유한요소해석을 결합한 역해석이 발전하였다. 특히 잔류 표면 형상(residual imprint)은 하중-깊이 곡선이 담지 못하는 정보를 제공하는 보완 응답으로 인식되어 왔다.

잔류 프로파일과 잔류응력의 관계는 정량적으로도 뒷받침된다. Shen et al.(2015)은 잔류 표면 프로파일로부터 잔류응력을 수치적으로 결정할 수 있으며, 특히 최대 pile-up 높이가 잔류응력에 민감한 지표임을 보였다.^[15] 이는 무응력 상태 대비 pile-up 높이의 변화가 잔류응력의 크기·방향과 연결됨을 의미하므로, 최대 pile-up 높이를 비롯한 프로파일 형상 특징을 신경망의 입력 특징으로 사용하는 것이 타당함을 시사한다. 한편 잔류 자국만으로 탄소성 물성을 식별하려는 시도들도 보고되었으며, 최근 연구는 잔류 자국 데이터만으로도 Voce 파라미터, 항복강도, 탄성계수 등의 예측에 유의미한 차이가 없을 수 있음을 보였다.^[10]

제 5 절 FE-ANN 기반 역해석과 표현학습

유한요소해석은 재료 모델과 접촉 조건이 주어졌을 때 압입 곡선과 잔류 형상을 생성할 수 있으므로, 파라미터 변화에 따른 대규모 학습 데이터베이스를 구축하는 데 효과적이다. Jeong et al.(2020)은 다양한 경화 파라미터 조합에 대한 FE 기반 구형 압입 시뮬레이션으로 ANN 학습용 데이터베이스를 구성하고, 입력 인코딩과 하이퍼파라미터 최적화를 통해 실제 압입 데이터로부터 일축 인장 유동을 안정적으로 예측할 수 있음을 보였다.^[4] 이는 비파괴 압입 데이터로부터 등방 인장 거동을 역해석할 수 있음을 보인 본 연구의 직접적 출발점이다. 이 흐름은 이후 변형장 정보를 적극 활용하는 방향으로 확장되었다. Jeong et al.(2022, 2024)은 하중-깊이 곡선과 함께 면내(in-plane)·수직(vertical) 변위장 또는 반경·수직 변위 프로파일을 사용하는 FE-NN 모델을 제시하면서, 구형 압입에서는 하중-깊이 곡선만으로는 충분하지 않고 적어도 하나 이상의 변형장 정보가 함께 제공되어야 한다는 점을 보였다.^{[5],[6]} 본 연구는 이 방법론적 통찰을, 재료 이방성이 아니라 잔류응력 추정 문제에 적용한다. 즉, 잔류 z-프로파일이라는 변형장 정보를 도입함으로써 하중-깊이 곡선만으로는 식별 불가능한 잔류응력을 추정 가능하게 한다.

표현학습 모델은 입력 표현의 질에 민감하다. Jeong et al.(2020)은 압입 곡선을 그대로 쓰는 대신 인코딩 계층으로 차원을 축소하고 노이즈를 처리함으로써 성능을 개선하였다.^[4] 본 연구는 이를 잔류 z-프로파일에 적용하여, CNN(공간적 형상 패턴), VAE(확률적 잠재공간), LSTM(순차 의존성) 세 가지 표현학습 모델을 잠재특징 추출기로 비교한다.

제 6 절 본 연구의 위치와 차별성

이상을 종합하면, 압입 기반 역해석 연구는 하중-깊이 곡선 기반의 등방 경화 추정에서 출발하여 잔류 자국·변형장 정보를 활용하는 방향으로 발전해 왔다. 본 연구는 이 흐름 위에서, 구형 압입의 하중-깊이 곡선과 잔류 z-프로파일을 함께 이용하여 경화 파라

미터와 이축 잔류응력을 동시에 추정하고, 물리 기반 스칼라 특징·표현학습·데이터 증강으로 sim-to-real 간극과 역문제의 불안정성을 완화하고자 했다는 점에서 차별성을 가진다. 다시 말해 본 연구는 기존 FE-ANN indentation plastometry를, 잔류응력 추정과 잔류 z-프로파일 기반 표현학습의 방향으로 확장한 시도이다.

제 3 장 연구 방법

제 1 절 연구 흐름

본 연구의 전체 파이프라인은 그림 3과 같다. ① 경화 파라미터(K, ϵ_0, n)와 이축 잔류응력(R_{sx}, R_{sy})을 입력으로 설정하고, ② 구형 압입에 대한 유한요소해석을 수행하여, ③ 하중-깊이 곡선과 압입 후 잔류 z-프로파일 장(field)을 출력으로 얻는다. ④ 얻어진 응답에 물리 기반 특징 추출과 데이터 증강을 적용하고, ⑤ 압입 응답을 입력, 경화 파라미터·잔류응력을 출력(target)으로 하여 신경망을 학습한다. ⑥ 마지막으로 실제 압입 시험에서 얻은 응답을 학습된 신경망에 입력하여 물성을 추론하고, ⑦ 그 결과 중 경화곡선 복원 결과를 일축 인장시험 결과와 비교·검증한다.




그림 3 본 연구의 전체 흐름도.

제 2 절 재료 거동 모델 및 입력 파라미터 설정

소성 경화는 Swift 경화 법칙으로 기술하고 항복은 등방 von Mises 기준을 따른다.

$$\text{Swift Hardening law: } \sigma = K(\epsilon_0 + \epsilon_p)^n$$

$$\text{Von-Mises Criterion } \sigma_y = \sqrt{\frac{1}{2}[(\sigma_{11}-\sigma_{22})^2 + (\sigma_{22}-\sigma_{33})^2 + (\sigma_{33}-\sigma_{11})^2] + 3(\sigma_{12}^2 + \sigma_{23}^2 + \sigma_{31}^2)}$$

여기서 σ 는 응력, σ_y 는 항복강도, ϵ_p 는 등가 소성변형률, K 는 강도계수, ϵ_0 는 초기 변형률, n 은 경화지수이다. . 잔류응력은 면내 x방향과 y방향 성분 R_{sx} , R_{sy} 로 부여하며, $R_{sx} \neq R_{sy}$ 인 비등방(이축) 잔류응력 상태를 포함한다. 본 연구에서 재료의 항복 자체는 등방으로 가정하므로, 잔류 z-프로파일의 방향 의존성은 재료 이방성이 아니라 부여된 잔류응력의 방향성에서 비롯된다.

예측 물질은 구리로 탄성계수는 $E = 130$ GPa, Poisson 비는 $\nu = 0.3$ 으로 고정하였다. 예측 파라미터는 K , ϵ_0 , n , R_{sx} , R_{sy} 의 총 5개이다. 데이터베이스 구축에 사용한 각 파라미터의 무작위 추출 범위(최소~최대)는 표 3-1과 같다(표 1, 총 1,999개 조합).

파라미터	최소	최대	평균
K(MPa)	150	1,000	574
ϵ_0	0.001	0.099	0.050
n	0.1	0.8	0.447
R_{sx} (MPa)	-313	352	0
R_{sy} (MPa)	-360	373	0

표 1 입력 파라미터 범위 (1,999개 조합)

제 3 절 유한요소해석 기반 데이터베이스 구축

실험 데이터를 대량으로 확보하는 것은 비용·시간 측면에서 매우 부담이 크므로, 본 연구는 유한요소해석으로 합성 데이터베이스를 구축하였다. 정의된 파라미터 범위에서 무작위로 값을 추출하여 총 1,999개의 입력 조합을 생성하고, 각 조합에 대해 구형 압입 해석을 수행하여 하중-깊이 곡선과 잔류 z-프로파일을 산출하였다.

유한요소해석은 Abaqus/Explicit으로 수행하였으며, 소성 경화는 Swift 법칙을 구현한 사용자 정의 서브루틴(VUHARD, 등방경화) 으로 정의하였다.

$$\sigma_y = K(\epsilon_0 + \epsilon_p)^n, \epsilon_p \leq 0 \rightarrow \sigma_y = K \cdot \epsilon_0^n$$

주요 해석 조건은 다음과 같다. 모델 형상은 잔류응력이 이축 비대칭($R_{sx} \neq R_{sy}$)이어서 축대칭 가정이 성립하지 않으므로, 두 대칭면(XSYM, YSYM)을 갖는 3차원 1/4 대칭 모델을 사용하였다. 시편은 8절점 육면체 감차적분 요소(C3D8R), 압입자는 강체(R3D3·R3D4, 강체 참조점 기준)로 모델링하였다. 압입자 및 압입 깊이는 반경 $R = 500 \mu\text{m}$ 구형 강체 압입자, 최대 압입 깊이 $0.075 \text{ mm}(= 75 \mu\text{m}, h/R = 15\%)$ 를 사용하였다.(그림 4) 재료는 일반적인 구리의 물성, $E = 130$ GPa, $\nu = 0.3$, 밀도 $8.05 \times 10^{-9} \text{ ton/mm}^3$ 을 사용하였다. 마찰계수 $\mu = 0.12$, hard pressure-overclosure, 운동학적(kinematic) 접촉 조건을 사용하였다. 잔류응력은 초기 응력장(Initial Conditions, type=STRESS)으로 $\sigma_{xx} = R_{sx}$, $\sigma_{yy} = R_{sy}$ 를 부여하고, 평형 유지를 위해 동일 크기의 체적력(BX, BY)을 함께 적용하였다. 하중은 압입자 참조점의 변위 제어로 $t = 0 \rightarrow 1.5$ 에 최대 깊이까지 부하한 뒤 $t = 1.5 \rightarrow 2.25$ 에 제하하였다(2단계 Dynamic Explicit). 준정적 해석의 안정성을 위해 가변 mass scaling(목표 $\Delta t = 1 \times 10^{-4}$)과 bulk viscosity(0.06, 1.2)를 적용하였다.




그림 4 유한요소해석 실험

제 4 절 입력 데이터 구성

신경망의 입력은 단순한 1차원 벡터가 아니라 두 종류의 응답으로 구성된다. 첫째는 하중-깊이 곡선이며, 둘째는 0° , 45° , 90° 세 방향의 잔류 z -프로파일이다. 등방 재료의 경우 무응력 상태에서 세 방향 프로파일은 이론적으로 동일하므로, 이 성질을 데이터 증강(방향 shuffle)에 활용할 수 있다. 반면 이축 잔류응력이 부여되면 세 방향 프로파일이 서로 달라지며, 이 방향 의존성이 R_{sx} 와 R_{sy} 를 식별하는 정보가 된다. 최종 입력 벡터는 하중 5점과 3방향 잔류 z -프로파일(방향당 400점)을 합친 1,205차원이다.

잔류 z -프로파일은 접촉 영역 인접 구간에서 가장 풍부한 정보를 담으므로, 적절한 반경 구간으로 잘라내는(crop) 전처리가 성능에 영향을 준다. 예비 분석에서 실험-시뮬레이션 프로파일의 정합도(R^2)는 비교 구간에 따라 크게 달라졌으며, 특정 구간에서 정합도가 현저히 높아지는 경향이 관찰되었다. 이에 따라 본 연구는 원시 프로파일, crop된 프로파일, 그리고 물리 기반 스칼라 특징의 조합을 예비적으로 검토하였다. 다만 이 입력 표현의 효과는 증강 기법 및 모델 구조와 강하게 상호작용하였으므로, 결과 해석에서는 제4장 제1절과 제5장 제2절에서 그 한계를 함께 논의한다.

제 5 절 입력 데이터 구성

Jiao et al. (2024)의 방법과 유사하게 잔류 프로파일 $z(r)$ 의 형상 정보를 저차원으로 압축하기 위해 다음의 물리 기반 특징을 추출하였다.^[7](표 2)

특징	정의	의미
A	$A = \int z(r)dr$	프로파일 단면적
V	$V = 2\pi \int rz(r)dr$	축대칭 회전체 부피
d_{mc}	$\argmax_r z(r)$	최대 높이(pile-up) 발생 반경
h_{max}	$\max z(r) - z(0)$	중심 대비 최대 높이차

표 2 입력 데이터에서 추출한 다른 특성 값.

이들 특징은 잔류 프로파일의 형상을 소수의 스칼라로 압축하여 학습 안정성을 높이려

는 목적을 가진다. 특히 최대 pile-up 높이($h_{\max}$)는 제2장에서 논의한 바와 같이 잔류응력에 민감한 물리 지표이다.

제 6 절 인공신경망 구조 설계

전체 신경망은 (i) 잔류 z -프로파일로부터 잠재특징을 추출하는 인코더와 (ii) 하중-깊이 입력 및 물리 기반 스칼라 특징과 결합하여 최종 물성을 회귀하는 완전연결(FC) 부분으로 구성된다. 여기서 물리 기반 스칼라 특징은 제5절의 A , V , d_{mc} , $h_{\max}$ 와 같이 사람이 정의한 저차원 입력을 의미하며, 잠재특징은 인공신경망 인코더가 잔류 z -프로파일로부터 학습하는 표현을 의미한다. 잠재특징 추출기로는 CNN/VAE/LSTM 인코더 세 가지 후보를 비교하였다.

추출된 잠재특징은 하중-깊이 입력 및 (선택적) 물리 기반 스칼라 특징과 결합(concatenate)된 뒤 은닉 FC 계층을 거쳐 최종 출력 K , ϵ_0 , n , Rs_x , Rs_y 를 산출한다(그림 5). 베이지안 최적화로 선정된 최종 CNN 구조는 합성곱 7층(커널 (3,5), 초기 채널 30), 잠재차원 30, 최종 FC 7층(각 249 노드)이다.




그림 5 인공신경망 모델 구조

제 7 절 데이터 증강을 통한 sim-to-real gap 완화

유한요소 데이터로 학습한 모델을 실제 실험에 적용할 때 발생하는 시뮬레이션-실험 간극을 완화하기 위해, 시계열 데이터에 널리 쓰이는 세 가지 증강 기법을 잔류 z -프로파일에 적용하였다.(그림 6) 증강 데이터는 원본 학습 집합에 이어붙여 사용하였다.




그림 6 잔류 z-프로파일에 적용한 데이터 증강 기법의 예시

- Gaussian jittering: 값에 비례한 가우시안 노이즈를 삽입한다.

$x_z \leftarrow x_z \cdot (1 + \text{snr} \cdot N(0,1))$. (본 연구: $\text{snr} = 0.02$)

- Magnitude warping: 프로파일을 n 개 구간으로 나누고 각 구간의 시작·끝 스케일을 무작위로 정하여 구간별 크기를 부드럽게 왜곡한다(piecewise linear). (본 연구: 5개 구간, $\text{scale} = 0.03$)

- Masking: 무작위 위치·길이의 블록을 0으로 가려, 모델이 특정 구간에 과의존하지 않도록 한다. (본 연구: 블록 폭 5~10, 프로파일당 8~16개 구간)

제 8 절 학습 및 평가 방법

신경망은 Adam 옵티마이저로 학습하였으며, 학습률 1×10^{-4} , 배치 크기 128, 최대 3,000 epoch, 가중치 감쇠 0으로 설정하였다. 전체 1,999개 데이터는 학습 80% / 검증 10% / 시험 10%로 무작위 분할하였고, 조기 종료는 검증 손실(val_loss)을 기준으로 하였다. 입력은 sample 단위 Min-Max 스케일링(하중과 z-프로파일을 분리하여 스케일)을, 출력 파라미터는 Min-Max 스케일링을 적용하였으며, 잔류응력 출력은 시편별 항복강도로 정규화하였다. CNN 구조(합성곱 층 수·필터·채널·FC 차원 등)는 검증 손실을 목적함수로 한 베이지안 최적화(약 50회 실행)로 탐색하였고, 잠재특징 추출기, 증강 기법, 물리 기반 스칼라 특징 사용 여부는 확정된 구조를 고정한 grid sweep으로 비교하였다.

평가 지표로는 대칭 평균 절대 백분율 오차(SMAPE)를 주 지표로 사용하고, 결정계수 R^2 를 보조 지표로 사용하였다. SMAPE를 채택한 이유는, 잔류응력 등 일부 출력이 0 근처 값을 포함하므로 0 근방에서 분모가 발산하지 않고 대칭적·안정적으로 상대오차를 평가할 수 있기 때문이다.

$$SMAPE = \frac{1}{n} \sum_{i=1}^n \frac{|\hat{y} - y|}{(|\hat{y}| + |y|)/2}$$

제 4 장 결과 및 분석

제 1 절 데이터 증강의 영향

잠재특징 추출 모델 비교(제2절)에 앞서, 먼저 VAE를 기준으로 삼아 네 가지 증강 조건(무증강, Gaussian jittering, magnitude warping, masking)을 grid sweep으로 바꿔가며 증강 기법의 경향을 선별하였다. 이 단계의 목적은 최종 모델을 결정하는 것이 아니라, 실험 데이터에 적용했을 때 시뮬레이션-실험 간극에 가장 안정적으로 대응하는 증강 방식을 고르는 데 있었다. 실험 데이터에서는 잔류응력의 직접 참값이 없으므로, 경화곡선 복원 양상, 반복 압입 응답 간 예측 안정성, 그리고 잔류 z -프로파일의 교란 양상을 함께 고려하였다.(그림 7)




그림 7 증강 기법별 실험 데이터에 대한 영향(VAE 모델, 베이지안 최적화 후). (a) 무증강, (b) Gaussian jittering, (c) Magnitude Warping (d) Masking

전반적으로 적절한 증강은 모델이 특정 구간에 과의존하는 것을 완화하여 시뮬레이션-실험 간극을 줄이는 방향으로 작용하였다. 다만 기법별 효과는 균일하지 않았다. Gaussian jittering은 대부분의 경우 효과가 제한적이었고, magnitude warping은 성능과 별개로 결과의 편차를 키워 강건성(robustness)을 저하시키는 경향을 보였다. 반면 masking은 비교적 일관된 개선을 보였으며, 특히 프로파일을 crop한 경우에 효과가 두드러졌다. 물리 기반 스칼라 특징(A, V, d_{mc}, h_{max})의 추가는 일부 MLP 및 CNN 계열 설정에서 검증·시험 성능을 개선했으나, 입력 구간과 증강 방식에 따라 효과가 달라져 최종 성능 개선 요인으로 일반화하기는 어려웠다. 특히 masking은 일부 값을 0으로 치환하므로, 스칼라 특징값을 함께 사용할 때 해당 특징 자체를 교란하여 불리하게 작용하는 경우가 있었다. 따라서 본 연구에서는 masking을 최종 증강 기법으로 채택하되, 물리 기반

특징의 효과는 제5장 제2절에서 한계와 함께 해석한다.

제 2 절 잠재특징 추출 모델 비교

잔류 z-프로파일의 잠재특징 추출기로서 CNN, VAE, LSTM을 SMAPE 기준으로 비교한 결과는 표3과 같다. 값이 작을수록 우수하다.

파라미터	CNN	VAE	LSTM
K	0.039	0.069	0.075
ϵ_0	0.199	0.205	0.452
n	0.073	0.072	0.168
R _{sx}	0.238	0.186	0.168
R _{sy}	0.212	0.196	1.128

표 3 모델, 파라미터별 SMAPE

경화 파라미터 K와 ϵ_0 에서는 CNN이 가장 우수하였고, n에서는 CNN과 VAE가 사실상 동등하였다. 반면 이축 잔류응력 R_{sx}, R_{sy}에서는 VAE가 근소하게 앞섰다. LSTM은 모든 항목에서 열세였으며, 특히 잔류응력에서 SMAPE가 1.0을 초과하는 큰 오차와 학습 불안정성을 보였다. 따라서 잔류응력 단독 성능만 보면 VAE를 선택할 여지가 있지만, 실제 실험 검증에서 직접 대조 가능한 것은 경화 파라미터로 복원한 응력-변형률 곡선이며, 이 관점에서는 K와 ϵ_0 의 안정성이 중요하다. 본 연구는 경화곡선 복원 신뢰도와 전체 학습 안정성을 우선하여 최종 모델로 CNN을 채택하고, 증강은 masking을 결합하였다. 이 선택은 잔류응력 추정에서 VAE 대비 일부 성능을 포기하는 절충이며, 그 한계는 제5장에서 논의한다.

제 3 절 최종 모델의 시험 데이터 예측 성능

최종 모델(CNN + masking)의 Test(시뮬레이션) 데이터에 대한 예측값-참값 비교 결과는 그림8과 같다. 경화계수 K($R^2 = 0.9931$), 경화지수 n(0.9885), 이축 잔류응력 R_{sx}(0.9928)·R_{sy}(0.9921)는 모두 0.99 내외의 높은 결정계수를 보였다. 반면 ϵ_0 는 $R^2 = 0.8364$ 로 상대적으로 낮았으며, 이는 표 3에서 ϵ_0 의 SMAPE가 가장 컸던 결과와 일관된다. 파라미터별 성능 차이의 원인은 제5장 제4절에서 분석한다.

제 4 절 응력-변형률 곡선 복원 결과

예측된 Swift 파라미터(K, ϵ_0 , n)로부터 응력-변형률 곡선을 복원하여, Test(시뮬레이션) 데이터와 실험 데이터 각각에 대해 비교하였다. 단일 파라미터 수치의 일치보다, 실제 물성 곡선 수준에서의 복원이 공학적으로 더 직관적인 검증이 된다. 복원된 곡선은 시험 데이터에서 기준 곡선과 잘 일치하였으며, 실제 구리 시편의 압입 응답에 대해서도 인장시험 기반 기준 곡선의 전반적 경화 경향을 재현하였다(그림 9). 다만 이 일치는 경화

곡선 수준의 검증이며, 잔류응력과 ϵ_0 의 절대 정확도까지 동일하게 보장하지는 않는다.




그림 8 최종 모델(CNN+masking)의 Test data 예측비교 및 파라미터별 R^2 (Min-Max 표준화 기준).




그림 9 예측된 Swift 파라미터로 복원한 응력-변형률 곡선(좌: Test(시뮬레이션) data, 우: Test(실험) data).

검증을 위해 실제 구리(Cu) 시편에 대해 $R = 500 \mu\text{m}$ 구형 압입 시험을 수행하였다. 이를 학습된 최종 모델에 입력하여 경화 파라미터와 잔류응력을 추론하고, 추론된 경화 파라미터로 복원한 응력-변형률 곡선을 동일 구리의 일축 인장시험 결과와 비교하였다. (그림 9(b)) 경화 거동의 기준값(ground truth)은 일축 인장시험(구리 인장 시편 2개)으로 얻은 응력-변형률 곡선에 Swift 식을 피팅한 $K = 489.72 \text{ MPa}$, $\epsilon_0 = 0.0016$, $n = 0.451$ 이다. 비교 결과 경화곡선의 전체적인 형태는 합리적으로 재현되었으나, 실험 데이터에 대해서는 잔류응력의 독립 참값이 없어 잔류응력 추정의 절대 정확도를 직접 검증할 수는 없었다. 또한 ϵ_0 추정과 접촉부 z-프로파일 정합성에서는 제5장에서 논의하는 한계가 관찰되었다.

제 5 장 논의

제 1 절 본 연구 결과의 의미

본 연구는 비파괴 압입 응답만으로 경화 파라미터와 이축 잔류응력을 동시에 추정하려는 시도였다는 점, 그리고 하중-깊이 곡선에 거의 흔적을 남기지 않는 잔류응력을 잔류 z -프로파일을 적극 활용함으로써 식별하려 했다는 점에서 의의를 가진다. 또한 CNN 기반 역해석이 시뮬레이션 데이터를 넘어 실제 실험 데이터에서도 응력-변형률 곡선 복원 가능성을 보였다는 점은, 본 방법이 파괴 시험의 완전한 대체가 아니라 비파괴적 보완 추론 도구로서 가치를 가짐을 시사한다. 다만 실제 실험에서는 잔류응력의 독립 기준값이 확보되지 않아, 잔류응력 성능은 주로 시뮬레이션 시험 데이터와 프로파일 물리 해석을 통해 평가되었다.

제 2 절 물리 기반 특징 추출의 유효성과 한계

예비 실험에서 z -프로파일의 물리 기반 스칼라 특징 추출은 MLP 및 CNN 계열 모델의 검증·시험 성능을 개선하는 경우가 있었다. 그러나 이 특징이 항상 유리한 것은 아니었으며, 그 한계의 원인은 다음 세 가지로 정리된다. 첫째, 모든 데이터가 뚜렷한 pile-up 형상을 보이지는 않아 일부 특징(예: 최대 pile-up 위치)이 안정적으로 정의되지 않았다. 둘째, 정보가 풍부한 좁은 반경 구간으로 프로파일을 제한할 경우 형상 정보의 일부가 손실되었다. 셋째, 데이터 증강, 특히 masking이 스칼라 특징값을 직접 교란하여 물리 기반 특징 추출과 충돌하였다. 따라서 본 연구에서 물리 기반 특징은 보조 입력으로는 의미가 있으나, 원시 또는 절단 z -프로파일을 대체하는 일반적 해결책으로 보기는 어렵다.

제 3 절 증강 기법별 해석

masking이 상대적으로 유효했던 것은, 무작위 구간을 가림으로써 모델이 특정 구간에 과의존하지 않도록 정규화 효과를 주었기 때문으로 해석된다. 반면 magnitude warping은 프로파일의 크기를 인위적으로 왜곡하여 결과 편차를 키웠고, Gaussian jittering은 비례 노이즈만으로는 시뮬레이션-실험 간극의 구조적 차이를 충분히 반영하지 못한 것으로 보인다. 또한 masking이 물리 기반 스칼라 특징과 충돌한다는 사실은, 증강과 입력 표현(raw profile vs. cropped profile vs. scalar feature)을 독립적으로가 아니라 상호작용을 고려하여 함께 설계해야 함을 보여준다.

제 4 절 ϵ_0 예측 성능 저하 원인 분석

표 3과 제4장 제3절에서 일관되게 나타난 ϵ_0 의 상대적 저성능은 다음 요인들로 설명된다. 첫째, ϵ_0 는 그 값이 작고(0.001~0.099) 강도계수 K ·경화지수 n 과 강하게 결합되어 있어 압입 응답에 미치는 단독 영향이 작다. 특히 본 연구의 압입은 깊이가 커($h/R = 15\%$) 큰 소성변형 영역의 거동이 응답을 지배하므로, 항복 부근을 규정하는 ϵ_0 의 민감도가 상대적으로 낮다. 둘째, Swift 식은 항복 이전 구간을 정확히 근사하지 못하며, 본 연구의 압입점이 이론적 항복점 부근에 위치하여 Swift 식의 불확실성이 큰 영역에 해당하였다. 셋째, ABAQUS FEA에서 사용한 사용자 정의 소성 모델(Swift 경화)이 항복강도를 명시적으로 고려하지 않아 항복강도가 과소평가되는 경향이 있었다. Swift 경화식 피팅값이 전체 응력-변형률 곡선은 잘 맞춰도, 항복 직전/항복 부근의 실제 거동을 정확히 맞추는 보장은 없다. 특히 현재 구리 피팅값처럼 ϵ_0 가 매우 작으면 초기 항복강도가 낮게 계산될 수 있다. 따라서 항복 부근을 보다 정확히 기술하는 구성모델(예: 0.2% offset 이전을 선형으로 처리하는 경화 알고리즘)을 도입하면 ϵ_0 예측이 개선될 것으로 기대된다.

제 5 절 시뮬레이션-실험 간극의 원인

제4장에서 실험 구리 시편의 응력-변형률 곡선은 전반적으로 복원되었지만, 이는 경화 곡선 수준의 일치이며 잔류 z -프로파일의 모든 구간이 정합되었다는 뜻은 아니다. 실제 실험 적용 시 관찰된 시뮬레이션-실험 간극은 접촉부 잔류 z -프로파일에서 특히 크게 나타났으며, 단일 원인으로 확정하기 어렵다. (그림12)




그림 10 시뮬레이션-실험 잔류 z -프로파일 비교. 접촉 구간(적색 표시)에서 큰 간극이 있다.

첫째, Abaqus 에서 중심점 z 변위의 진동이 관찰되었는데, 이는 실제 실험의 물리적 충돌이라기보다 mass scaling, 감쇠(damping) 부족, 접촉 알고리즘 등에서 비롯된 동적 효과 또는 수치적 접촉 진동일 가능성을 시사한다. 언로딩 속도 조절, holding, mass scaling 비율 조정에도 간극이 완전히 해소되지 않은 점은 접촉 조건의 민감성을 보여준다. 둘째, Swift 경화식을 사용자 정의 소성 모델로 구현하면서 실제 0.2% offset 항복강

도를 별도로 맞추지 않았기 때문에 항복 부근 유동응력이 과소평가되었을 가능성이 있다. 이는 ε_0 저성능과도 연결된다. 셋째, 실제 구리 시편의 미세조직, 사전 가공경화, 초기 잔류응력 상태가 이상화된 등방 Swift 재료와 달랐을 가능성도 있다. 따라서 이 간극은 충돌 하나가 아니라 수치 접촉 조건, Swift 모델의 항복 부근 부정확성, 실제 시편 상태 불일치가 중첩된 결과로 해석하는 것이 더 안전하다. 향후에는 접촉 감쇠·mass scaling 민감도 분석, 0.2% offset 항복 이전 구간을 반영한 경화 알고리즘, 다양한 가공 이력의 구리 시편 검증이 필요하다.

제 6 장 논의

제 1 절 본 연구 요약

본 연구는 구형 압입의 하중-깊이 곡선과 잔류 z -프로파일을 입력으로, 재료의 경화 파라미터(K , ε_0 , n)와 이축 잔류응력(R_{sx} , R_{sy})을 동시에 추정하는 딥러닝 기반 역해석 프레임워크를 제안하였다. 잔류응력이 하중-깊이 곡선에는 거의 영향을 주지 않는다는 물리적 사실에 근거하여 잔류 z -프로파일을 핵심 입력으로 채택하였고, Swift 경화 법칙과 von Mises 기준에 기반한 1,999개 조합의 유한요소 데이터베이스로 신경망을 학습하였다. 물리 기반 스칼라 특징, 시계열 데이터 증강, 세 가지 잠재특징 추출기를 비교한 결과, 경화 파라미터에는 CNN이, 잔류응력에는 VAE가 상대적으로 유리하였다. 최종적으로는 실제 실험에서 검증 가능한 경화곡선 복원과 학습 안정성을 우선하여 CNN과 masking을 결합한 구성을 채택하였으며, 실제 구리 시편에서 응력-변형률 곡선 복원 가능성을 확인하였다

제 2 절 주요 성과

본 연구의 주요 성과는 아래와 같다.

1. 비파괴 단일 구형 압입 응답으로부터 경화 파라미터와 이축 잔류응력을 동시에 추정하는 프레임워크를 제안하였다.
2. 잔류 z -프로파일의 물리 기반 스칼라 특징 활용과 잠재특징 추출기 (CNN/VAE/LSTM) 비교를 수행하여, 경화 물성에는 CNN이, 잔류응력에는 VAE가 유리함을 정량적으로 규명하였다.
3. 시험 데이터에서는 잔류응력을 포함한 다중 파라미터 예측 성능을 확인하고, 실제 구리 실험 데이터에서는 응력-변형률 곡선 복원 가능성을 확인하였다. 동시에 수치 접촉 조건, Swift 식 항복 부근 불확실성, 실제 시편 상태 차이를 간극의 주요 후보로 분석하였다.

제 3 절 향후 연구 방향

첫째, 다중충실도 신경망(MFNN)은 대량의 저충실도 데이터(시뮬레이션)와 소량의 고충실도 데이터(실험)를 분리·결합 학습하여, 두 데이터 비율이 크게 차이더라도 sim-to-real 간극을 효과적으로 좁힐 수 있다(그림 11).^[12] 실험 데이터가 축적되면 본 구조를 이 방향으로 확장할 수 있다. 둘째, 물리정보 신경망(PINN)은 접촉역학에서 유도되는 실험식(접촉면적·평균압력·E/YS 관계 등)을 물리 손실로 추가하여, 데이터 기반 학습에 물리적 일관성을 부여할 수 있다(그림 12).^{[3],[13]} 셋째, 항복 부근을 보다 정밀하게 기술하는 구성모델(예: 0.2% offset 이전 선형화)을 도입하여 ϵ_0 추정 정밀도를 높일 수 있다.

Multi Fidelity Neural Net(MFNN)

- Effectively close sim2real gap at low exp/sim ratio





그림 11 다중충실도 신경망(MFNN)의 개념. 대량의 저충실도(시뮬레이션) 데이터와 소량의 고충실도(실험) 데이터를 결합 학습한다.^[12]

Physics-Informed Neural Net(PINN)

- Developing Physics-Informed Loss from Experimental Equations from Contact Problem



$$\sigma_{y,Swift} = K\epsilon_0^n$$

$$M = \frac{(1.45 + 28.55n + 1745\sigma_y^*)(1 - 0.5n + 20\sigma_y^*)}{(1 + 21.4n + 1020\sigma_y^*)(1 + 0.4n + 60\sigma_y^*)}$$

$$N = \frac{(1.9 + 12.5n + 570\sigma_y^*)(1 + 0.1n)}{(1 + 6.8n + 340\sigma_y^*)}$$

$$\text{where } \sigma_y^* = \frac{\sigma_y}{E}$$

$$c'^2 = \frac{h_c}{h} = M \left[2 \left(1 - \sqrt{1 - a_c^2} \right) \right]^{(2-N)/2}$$

where a_c is contact radius, h_c is indentation depth at contact point

그림 12 접촉역학 실험식에서 유도한 물리 손실을 활용하는 물리정보 신경망(PINN)의 개념.^{[3],[13]}

참 고 문 헌

1. Field, J. S. & Swain, M. V. A simple predictive model for spherical indentation. *J. Mater. Res.* **8**, 297-306 (1993).
2. Francis, H. A. Phenomenological analysis of plastic spherical indentation. *J. Eng. Mater. Technol.* **98**, 272-281 (1976).
3. Hernot, X., Bartier, O., Bekouche, Y., El Abdi, R. & Mauvoisin, G. Influence of penetration depth and mechanical properties on contact radius determination for spherical indentation. *Int. J. Solids Struct.* **43**, 4136-4153 (2006).
4. Jeong, K., Lee, H., Kwon, O. M., Jung, J., Kwon, D. & Han, H. N. Prediction of uniaxial tensile flow using finite element-based indentation and optimized artificial neural networks. *Mater. Des.* **196**, 109104 (2020).
5. Jeong, K., Lee, K., Lee, S., Kang, S.-G., Jung, J., Lee, H., Kwak, N., Kwon, D. & Han, H. N. Deep learning-based indentation plastometry in anisotropic materials. *Int. J. Plast.* **157**, 103403 (2022).
6. Jeong, K., Lee, K., Kwon, D., Lee, M.-G. & Han, H. N. Parameter determination of anisotropic yield function using neural network-based indentation plastometry. *Int. J. Mech. Sci.* **263**, 108776 (2024).
7. Jiao, Q., Chen, Y., Kim, J., Han, C., Chang, C. & Vlassak, J. J. A machine learning perspective on the inverse indentation problem: Uniqueness, surrogate modeling, and learning elasto-plastic properties from pile-up. *J. Mech. Phys. Solids* **185**, 105557 (2024).
8. Johnson, K. L. Contact mechanics (Cambridge University Press, 1985).
9. Kang, S.-K., Kim, Y.-C., Kim, K.-H., Kim, J.-Y. & Kwon, D. Extended expanding cavity model for measurement of flow properties using instrumented spherical indentation. *Int. J. Plast.* **49**, 1-15 (2013).
10. Kim, M.-S., Lee, T. & Kim, Y. Unique determination of material parameters from single spherical indentation data using artificial neural networks. *SSRN Electron. J.* 5343216 (2025).
11. Kværndrup, F. B., Engelbrekt, C., Küçükyıldız, Ö. C., Somers, M. A. J., Christiansen, T. L. & Winther, G. Area determination with pile-up and sink-in in nanoindentation of oxygen containing titanium. *Mater. Today Commun.* **30**, 103218 (2022).
12. Lu, L., Dao, M., Kumar, P., Ramamurty, U., Karniadakis, G. E. & Suresh, S. Extraction of mechanical properties of materials through deep learning from instrumented indentation. *Proc. Natl. Acad. Sci. U.S.A.* **117**, 7052-7062 (2020).
13. Marimuthu, K. P. & Lee, H. Physics-informed neural networks for spherical

- indentation problems. *Mater. Des.* **236**, 112494 (2023).
14. Mesarovic, S. D. & Fleck, N. A. Spherical indentation of elastic-plastic solids. *Proc. R. Soc. Lond. A* **455**, 2707-2728 (1999).
 15. Shen, L., He, Y., Liu, D., Gong, Q., Zhang, B. & Lei, J. A novel method for determining surface residual stress components and their directions in spherical indentation. *J. Mater. Res.* **30**, 1078-1089 (2015).
 16. Tabor, D. The hardness of metals (*Oxford University Press*, 1951).
 17. Yetna N'Jock, M., Chicot, D., Ndjaka, J. M., Lesage, J., Decoopman, X., Roudet, F. & Mejjias, A. A criterion to identify sinking-in and piling-up in indentation of materials. *Int. J. Mech. Sci.* **90**, 145-150 (2015).

Abstract

Prediction of Mechanical Properties and Residual Stress from Spherical Indentation Experiments via Deep-Learning-Based Inverse Analysis

Seyong Im

Department of Materials Science and Engineering

Interdisciplinary Major in Artificial Intelligence

Seoul National University

This study proposes a deep-learning-based inverse-analysis framework that simultaneously estimates the plastic hardening behavior and biaxial residual stress of a material from a non-destructive instrumented spherical indentation test. The inverse indentation problem is inherently non-unique—different parameter sets can reproduce similar indentation responses—and ill-conditioned, in that small measurement noise can cause large variations in the estimated parameters. Crucially, residual stress leaves almost no signature on the load-depth curve but is clearly imprinted on the residual surface profile; the present work therefore adopts the residual z -profile as the key input. A synthetic database was built by finite-element analysis of 1,999 parameter combinations defined under the Swift hardening law and the von Mises criterion, yielding load-depth curves and residual z -profiles. An artificial neural network was trained to output the hardening parameters (K , ϵ_0 , n) and the biaxial residual stresses (R_{sx} , R_{sy}). To mitigate the simulation-to-experiment gap, physics-based scalar features of the residual profile, three time-series data-augmentation techniques—Gaussian jittering, magnitude warping, and masking—and three latent-feature extractors (CNN, VAE, LSTM) were compared using the SMAPE metric. CNN performed best for the hardening parameters, whereas VAE was marginally superior for the residual stresses. The final configuration was chosen as CNN with masking because it provided stable hardening-curve reconstruction, which could be directly

checked against uniaxial-tension data. The final model achieved high coefficients of determination for most parameters on the synthetic test set, and the stress-strain curve reconstructed from the indentation response of a copper specimen agreed reasonably well with uniaxial-tension results. However, the absolute accuracy of residual-stress prediction could not be directly validated for the experimental specimen, and the predictions of ϵ_0 and residual stress were sensitive to the simulation-to-experiment gap in the contact-region z -profile. This gap was analyzed in terms of input-information limitations, uncertainty of the Swift law near yielding, and elastic-recovery mismatch at the indenter-specimen contact. This work demonstrates the potential of estimating hardening properties and residual stress from a single non-destructive indentation, and outlines extensions toward multi-fidelity and physics-informed neural networks.

keywords : Instrumented indentation, Residual stress, Inverse analysis, Artificial neural network, Convolutional neural network, Data augmentation